

Benchmark Veri Üzerinde Genetik Algoritma Destekli Özellik Seçimi, Optimizasyon Tabanlı Model Seçimi ve XAI Yöntemleri ile Yorumlanma Raporu

BÖLÜM 1 — ÖZET

Bu çalışmada saatlik PM2.5 hava kirliliğinin tahmin edilmesi problemi ele alınmıştır. Önce Genetik Algoritma ile en bilgilendirici özellikler seçilmiş, sonra üç farklı makine öğrenmesi modeli hiperparametre optimizasyonu ile eğitilmiştir. En yüksek başarıyı gösteren model, Açıklanabilir Yapay Zekâ yöntemleriyle yorumlanmıştır. SVR modeli en iyi sonucu üretmiş ($RMSE=4.40$, $R^2=0.949$), Permutation Importance ve LIME analizleri modelin hangi değişkenlere dayandığını ortaya koymuştur.

BÖLÜM 2 — GİRİŞ

Hava kalitesinin önceden tahmin edilmesi, halk sağlığı açısından büyük önem taşımaktadır. PM2.5 olarak adlandırılan ince partikül madde, solunum yolu hastalıklarıyla doğrudan ilişkilidir. Makine öğrenmesi yöntemleri bu alanda giderek daha fazla kullanılmaktadır; ancak yüksek tahmin başarısı tek başına yeterli değildir. Modelin hangi değişkenlere dayanarak karar verdiği de anlaşılmalıdır.

Bu çalışmada üç hedef belirlenmiştir.

1. Genetik Algoritma ile gereksiz özellikleri eleyerek modelin giriş uzayını küçültmek.
2. Farklı optimizasyon yöntemleriyle üç modeli kıyaslamak.
3. En iyi modelin karar sürecini XAI araçlarıyla açıklamak.

BÖLÜM 3 — PROBLEM TANIMI VE VERİ SETİ

3.1 Problem Tanımı

Bu çalışmada ele alınan problem, geçmiş meteorolojik ölçümler ve gecikmeli kirlilik verileri kullanılarak bir sonraki saatin PM2.5 konsantrasyonunun tahmin edilmesidir. Problem, zaman serisi tahmini olarak sınıflandırılmakta olup regresyon çerçevesinde modellenmiştir.

3.2 Veri Seti

Kaynak: UCI Machine Learning Repository — Beijing PM2.5 Data Set

Bağlantı: <https://archive.ics.uci.edu/dataset/381/beijing+pm2+5+data>

Lisans: Creative Commons Attribution 4.0 (CC BY 4.0)

Referans: Liang ve ark. (2015), Journal of Geophysical Research

Orijinal veri setinin istatistiksel yapısı korunarak 2.000 saatlik benchmark üretilmiştir.


Veri setinde 8 bağımsız değişken bulunmaktadır.

Değişken	Açıklama	Tür
pm25	Hedef değişken — PM2.5 konsantrasyonu ($\mu\text{g}/\text{m}^3$)	Hedef
temperature	Hava sıcaklığı ($^{\circ}\text{C}$)	Meteorolojik
wind_speed	Rüzgar hızı (m/s)	Meteorolojik
humidity	Bağıl nem (%)	Meteorolojik
pressure	Atmosfer basıncı (hPa)	Meteorolojik
hour	Günün saati (0–23)	Zamansal
pm25_lag1	1 saat önceki PM2.5	Türetilmiş
pm25_lag24	24 saat önceki PM2.5	Türetilmiş
pm25_roll6	Son 6 saatin ortalaması	Türetilmiş

3.3 Eğitim ve Test Bölümü

Zaman serisi verilerinde geleceğin geçmişten önce gelmesi durumuna veri sızıntısı (data leakage) denir. Bunu önlemek için veriler kronolojik sırayla bölünmüştür. İlk 1.600 gözlem eğitim (%80), son 400 gözlem test (%20) seti olarak ayrılmıştır. Veriler hiçbir şekilde karıştırılmamıştır. Çapraz doğrulama için TimeSeriesSplit (k=5) kullanılmıştır.

Şekil 1 — PM2.5 Veri Seti Genel Bakış
PM2.5 Zaman Serisi ($\mu\text{g}/\text{m}^3$)



BÖLÜM 4 — YÖNTEMLER

4.1 Genetik Algoritma ile Özellik Seçimi

Makine öğrenmesi modellerine tüm değişkenleri vermek her zaman iyi sonuç vermez. Gereksiz veya birbirine çok benzeyen değişkenler modeli olumsuz etkileyebilir. Çalışmada kullanılan değişkenlere Genetik Algoritma ile karar verildi.

Genetik Algoritma, biyolojik seçim ilkelerinden esinlenerek geliştirilmiş bir optimizasyon tekniğidir. Birbiriyle rekabet eden çözüm adaylarından en uygun olanlar bir sonraki nesle aktarılır. Bu çalışmada her potansiyel değişken kombinasyonu, ikili bir dizi şeklinde kodlanmış ve algoritmanın işlem birimi olarak kullanılmıştır. Kromozomdaki her bir “gen”, bir değişkene karşılık gelir. Gen 1 ise o değişken modele dahil edilmiş, 0 ise elenmiş demektir.

Örneğin 8 değişken için bir kromozom şu şekilde görünür:

[1, 0, 1, 0, 1, 1, 0, 1] → temperature, humidity, hour, pm25_lag1, pm25_roll6 seçildi

Algoritmanın adımları şunlardır:

Başlangıç popülasyonu: 15 rastgele kromozom üretildi. Her bireyden en az 3 değişken seçmesi zorunlu tutuldu.

Fitness fonksiyonu: Her kromozom, seçtiği değişkenlerle eğitilen Gradient Boosting modelinin 3-katlı çapraz doğrulama RMSE değeriyle değerlendirildi. Düşük RMSE, iyi birey anlamına gelir.

Turnuva seçimi: Her turda 3 birey rastgele seçildi, en düşük RMSE değerine sahip olan bir sonraki nesle geçme hakkı kazandı.

Tek noktalı çaprazlama: İki ebeveynin genleri rastgele bir noktadan bölünerek yeni bireyler üretildi. Çaprazlama oranı 0.80 olarak belirlendi.

Mutasyon: Her gen 0.15 olasılıkla tersine çevrildi (1→0 veya 0→1). Mutasyon, algoritmanın tek bir çözüme takılıp kalmasını önler.


Elitizm: Her nesilde en iyi 2 birey değiştirilmeden korundu.

Durdurma: 4 ardışık nesil boyunca iyileşme olmadığında algoritma durduruldu.

Sonuç: Algoritma 12 nesil çalışarak yakınsama sağladı. 8 değişkenden 3 tanesi seçildi, 5 tanesi elendi.

Seçilen değişkenler: humidity, hour, pm25_roll6 **Elenen değişkenler:** temperature, wind_speed, pressure, pm25_lag1, pm25_lag24

Şekil 2 — Genetik Algoritma Yakınsama Analizi



4.2 Modeller

Üç farklı makine öğrenmesi modeli seçilmiştir.

Random Forest: Birçok karar ağacını bağımsız olarak eğitip tahminlerin ortalamasını alan bir topluluk yöntemidir. Tek ağacın ezberlemesini önler, değişken önemini doğrudan verir.

Gradient Boosting: Ağaçları sıralı biçimde ekler; her yeni ağaç bir öncekinin hatasını düzeltmeye odaklanır. Genellikle yüksek doğruluk üretir ancak daha dikkatli ayarlama gerektirir.

SVR: Tahmin hatalarını belirli bir tolerans bandı içinde tutmayı hedefler. RBF çekirdeği ile doğrusal olmayan ilişkileri modelleyebilir. Ölçeklendirmeye duyarlıdır.

4.3 Hiperparametre Optimizasyonu

Her modelin ayarlanabilen parametrelerine hiperparametre denir. Bunları doğru seçmek performansı önemli ölçüde etkiler.

Grid Search (Random Forest ve SVR): Belirlenen tüm kombinasyonlar sırayla denenir. Küçük parametre uzayları için güvenilir ve sistematiktir.

Random Search (Gradient Boosting): Parametre uzayından rastgele örnekler seçilir. Geniş aralıklarda Grid Search'ten daha verimlidir.

Her iki yöntemde de TimeSeriesSplit çapraz doğrulama skoru kriter olarak kullanılmıştır.

4.4 Performans Metrikleri

RMSE: Büyük hataları daha çok cezalandırır. PM2.5 ile aynı birimde ifade edilir.

MAE: Hataların mutlak değerlerinin ortalamasıdır. Aykırı değerlere daha az duyarlıdır.

R²: Modelin hedef değişkenin değişkenliğini ne kadar açıkladığını gösterir. 1'e yakın olması iyidir.

MAPE: Yüzde cinsinden ortalama hata. Farklı problemlerle karşılaştırmayı kolaylaştırır.

BÖLÜM 5 — DENEYSEL ÇALIŞMA

5.1 Uygulama Ortamı

Tüm analizler Python'da gerçekleştirilmiştir. Kullanılan başlıca kütüphaneler :scikit-learn, pandas, numpy, matplotlib ve seaborn'dur.

5.2 GA Özellik Seçimi Sonuçları

Genetik Algoritma 12 nesil çalıştı ve yakınsama kriteri sağlanarak durdu. 8 değişkenden 3 tanesi seçildi. Seçilen değişkenler; nem (humidity), günün saati (hour) ve 6 saatlik hareketli ortalama (pm25_roll6) oldu. Lag değişkenlerinin elenmesi, bu veri setinde 6 saatlik hareketli ortalamanın kısa vadeli gecikmeli değerlerin bilgisini zaten özetlediğine işaret etmektedir.


5.3 Hiperparametre Optimizasyon Sonuçları

GA ile seçilen 3 değişken üzerinde modeller optimize edilmiştir.

Random Forest — Grid Search: En iyi parametreler: n_estimators=200, max_depth=10, min_samples_split=5

Gradient Boosting — Random Search: En iyi parametreler: n_estimators=203, max_depth=3, learning_rate=0.088, subsample=0.927


SVR — Grid Search: En iyi parametreler: C=50, epsilon=0.5, gamma='auto'



BÖLÜM 6 — SONUÇLAR VE KARŞILAŞTIRMALAR

6.1 Model Performansı

Model	Optimizasyon	RMSE	MAE	R ²	MAPE
Random Forest	Grid Search	4.8749	3.7623	0.9368	%6.35
Gradient Boosting	Random Search	4.6635	3.5812	0.9422	%5.88
SVR	Grid Search	4.4029	3.4107	0.9485	%5.59



6.2 Sonuçların Yorumu

SVR, tüm metriklerde en iyi sonucu üretmiştir. R²=0.949 değeri, modelin PM2.5 değişkenliğinin %94.9'unu açıkladığı anlamına gelir. MAPE=%5.59 ise ortalama hatanın gerçek değerın yalnızca %5.59'u olduğunu göstermektedir.

Gradient Boosting ikinci sıradadır. Random Search ile geniş bir parametre uzayı taranmış ve makul sonuçlar elde edilmiştir.

Random Forest en basit optimizasyona rağmen rekabetçi bir performans sergilemiştir. Bu, yöntemin genel sağlamlığını göstermektedir.


BÖLÜM 7 — XAI ANALİZİ

7.1 Permutation Feature Importance

Bu yöntem, her değişkeni sırayla karıştırarak modelin ne kadar bozulduğunu ölçer. Bir değişken karıştırıldığında RMSE ne kadar artarsa o değişken o kadar önemlidir. Her değişken için işlem 10 kez tekrarlanmıştır.

GA tarafından seçilen 3 değişken arasında pm25_roll6 en yüksek önemi göstermiştir. Bu, kısa vadeli PM2.5 trendinin tahmin için en belirleyici etken olduğunu ortaya koymaktadır.

Şekil 5 — XAI: Özellik Önemi — SVR (Grid Search)



SVR için dahili
özellik önemi
hesaplanamaz


7.2 LIME Analizi

LIME, seçilen bir test örneği çevresinde gürültü ekleyerek sahte örnekler üretir. Bu örnekler üzerinde basit bir doğrusal model eğitilir ve katsayılar bireysel katkıları gösterir.

Üç farklı PM2.5 seviyesini temsil eden örnekler için LIME açıklamaları üretilmiştir. Kırmızı çubuklar o değişkenin tahmini artırdığını, mavi çubuklar ise azalttığını göstermektedir.

Farklı örneklerde değişken katkılarının değişmesi, modelin koşullara göre uyum sağladığına işaret etmektedir.

Şekil 6 — LIME: Bireysel Tahmin Açıklamaları (3 Örnek)



BÖLÜM 8 — TARTIŞMA

En önemli kısım bu çalışmada, 8 değişkenden 5 tanesinin elenebilmesi ve yine de yüksek tahmin başarısı elde edilebilmesidir. Bu sonuç, her değişkenin modele katkı sağlamadığını ve gereksiz değişkenlerin hesaplama maliyetini artırdığını gösterebilir.

GA tarafından seçilen pm25_roll6 değişkeninin en önemli değişken olarak çıkması beklenen bir sonuçtur. 6 saatlik hareketli ortalama, kısa vadeli kirlilik trendini özetleyen güçlü bir göstergedir.

SVR'in en iyi sonucu vermesi, bu veri setindeki ilişkilerin doğrusal olmadığına ve çekirdek tabanlı yöntemlerin bu yapıyı daha iyi yakaladığına gösteriyor.

LIME analizlerinin farklı örneklerde farklı katkılar üretmesi, modelin tüm koşullarda aynı biçimde davranmadığını ve bölgeye özgü bir karar yapısına sahip olduğunu göstermektedir.

BÖLÜM 9 — SONUÇ

Bu çalışmada PM2.5 hava kalitesi tahmini, özellik seçimi, model optimizasyonu ve yorumlanabilirlik açısından ele alınmıştır. Genetik Algoritma 8 değişkeni 3'e indirmiş; bu sadeleştirilmiş giriş uzayında SVR modeli en iyi sonucu üretmiştir (RMSE=4.40, $R^2=0.949$). XAI analizleri, pm25_roll6 değişkeninin tahmininde belirleyici olmuştur.

Çalışmada , az sayıda doğru değişkenin çok sayıda değişkenden daha iyi sonuç verebileceğini ve makine öğrenmesi modellerinin yorumlanabilirlik açısından değerlendirilmesi gerektiğini gösteriyor.

BÖLÜM 10 — KAYNAKÇA

- [1] Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32.
- [2] Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *Annals of Statistics*, 29(5), 1189–1232.
- [3] Cortes, C., & Vapnik, V. (1995). Support-vector networks. *Machine Learning*, 20(3), 273–297.
- [4] Holland, J. H. (1975). *Adaptation in Natural and Artificial Systems*. University of Michigan Press.
- [5] Goldberg, D. E. (1989). *Genetic Algorithms in Search, Optimization, and Machine Learning*. Addison-Wesley.
- [6] Ribeiro, M. T., Singh, S., & Guestrin, C. (2016). "Why should I trust you?": Explaining the predictions of any classifier. *Proceedings of KDD 2016*, 1135–1144.
- [7] Fisher, A., Rudin, C., & Dominici, F. (2019). All models are wrong, but many are useful. *Journal of Machine Learning Research*, 20(177), 1–81.
- [8] Bergstra, J., & Bengio, Y. (2012). Random search for hyper-parameter optimization. *Journal of Machine Learning Research*, 13, 281–305.
- [9] Liang, X., ve ark. (2015). PM2.5 data reliability, consistency, and air quality assessment in five Chinese cities. *Journal of Geophysical Research: Atmospheres*, 120(20), 10440–10462.
- [10] Pedregosa, F., ve ark. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.